Everton Resende

AI Engineer

everton.augustor@gmail.com · +55 37 99913-3556 · linkedin.com/in/evertonresende
github.com/evertonresende · evertonresende.com
Pará de Minas, MG, Brasil · remoto (UTC-3)
Disponível para PJ, CLT ou contrato internacional

Construo e coloco em produção sistemas com LLMs, agentes e RAG, da arquitetura à infra, em TypeScript, Python, Cloudflare e AWS. **7+ anos desenvolvendo software**. IA em produção: agente de atendimento com evals, guardrails e supervisão humana (casos aprovados de 10 para 23 em 31, mesmo modelo), parecer de crédito com LLM a ~R$ 0,01 cada, reconhecimento facial para as escolas de uma prefeitura, notas clínicas por IA num SaaS usado por ~20 clínicas e um chat clínico com RAG. Workflow agent-first: defino arquitetura e critérios de aceite, oriento agentes de código, reviso, depuro e respondo pelo que vai para produção.

EXPERIÊNCIA PROFISSIONAL

AI Engineer — Coppay `10/2025 – 10/2026`

Fintech de conta digital e crédito · CLT · remoto

- **Parecer de crédito com LLM, em produção:** o gpt-oss-120b cruza bureau, SCR do Banco Central e simulações e devolve risco, valor, parcela e condições num schema fixo, a ~R$ 0,01 por parecer. Renda presumida sozinha não reprova: vira aprovação condicionada a comprovante. O analista decide.
- **App, BFF e back-office:** app em Expo nas lojas, com correntistas reais; BFF em Hono sobre Cloudflare Workers integrando Cronos, Asaas e HBI; back-office em Next.js com RBAC e audit log.
- **Novo BaaS:** em 09/2026, BFF novo sobre o BaaS do Asaas, com uma subconta por cliente, rodando lado a lado com o legado.
- **Agente de WhatsApp em Python:** construí com Agno + FastAPI um líder que faz a triagem para 3 especialistas, com tools de leitura presas ao contexto da conversa (sem IDOR) e handoff para humano.

`TypeScript · Expo · Hono · Cloudflare Workers · Durable Objects · Postgres · Python · FastAPI`

Desenvolvedor de Software — Softplan `11/2022 – 10/2025`

CLT · remoto

- Produtos para o Ministério Público e as Procuradorias.
- Reconhecido 10x no Softplayer A+.

Desenvolvedor de Software — FAPAM `11/2018 – 10/2021`

CLT · híbrido

- Portal acadêmico com 4.000+ alunos.

PROJETOS

Tazz — app de corridas `2026 – atual`

- **App novo em Expo:** arquitetei e construí do zero o app de passageiro e motorista e os Workers novos dele: auth próprio, hub em tempo real com Durable Objects e API sobre Postgres. Primeiras builds de produção em 10/2026, preparadas para substituir o app Flutter nas lojas.
- **Construído com agentes:** orquestrei agentes num backlog de ~200 frentes em paralelo, cada uma com prova por critério de aceite e revisão por um modelo de outro provedor; portões humanos em banco, main e lojas.
- **Migração:** o backend rodava em ~158 Cloud Functions e bateu na cota fixa de 20 vCPU do GCP em São Paulo com o app em operação. Portei 100+ delas para 8 Cloudflare Workers em ~47,5 h, em strangler-fig e com agentes de código.
- **Agente de atendimento:** em produção, com o atendente revisando cada rascunho. Portão de risco, dados pessoais mascarados, 9 tools com o ID do cliente vindo do servidor, guardrail que exige fonte para número e status, e LLM-juiz que só libera falso positivo, calibrado com 0 falsos bloqueios e 0 bypasses em 55 frases.
- **Evals:** 31 casos (7 adversariais), gate de zero respostas inseguras e 4 modelos comparados. Mesmo modelo, prompt e guardrail novos: aprovados de 10 para 23 e handoff de 80,6% para 38,7%. Demo pública do método: github.com/evertonresende/agent-evals-demo.
- **Base de conhecimento:** 58 entradas curadas, busca por palavra-chave e gatilho objetivo para reavaliar RAG.
- **Pagamentos:** PIX (Asaas) em produção desde 09/2026, sobre ledger de partida dobrada isolado.

`TypeScript · Expo · Cloudflare Workers · Durable Objects · Queues · Postgres`

Rota Protegida — reconhecimento facial escolar para prefeitura 2026

- **Produto:** câmeras IP na entrada das escolas identificam alunos e funcionários, registram a presença e avisam os responsáveis por WhatsApp e e-mail. Em produção desde 07/2026; entregue à prefeitura em 09/2026.
- **Reconhecimento em cascata:** uma VPS em Python detecta o rosto e extrai o embedding 512-D (AuraFace); a API em Hono sobre Cloudflare Workers busca no Vectorize; na zona cinza, o AWS Rekognition desempata, e o que segue em dúvida vai para revisão humana.
- **Decisão:** testei um 2º modelo (AdaFace) em ensemble e medi 862 eventos contra o veredito do AWS: nenhum match salvo e 45 rejeições erradas reforçadas. Desliguei.
- **LGPD:** biometria de crianças com consentimento obrigatório, retenção automática por tipo de dado, log de quem vê fotos e isolamento por escola no índice vetorial.

`TypeScript · Python · Hono · Cloudflare Workers · D1 · Vectorize · R2 · Queues · AWS Rekognition`

Maximus — app para anestesistas 2026

- **Produto:** app em Expo e API em Hono sobre Cloudflare Workers, com Supabase e RLS. No ar, em uso por anestesistas.
- **Chat clínico com RAG:** Responses API (gpt-5.4) com file_search sobre vector store da OpenAI, code interpreter para gráficos, streaming e pergunta por texto, imagem ou voz (gpt-4o-transcribe).
- **Questões do TSA:** geradas com structured output e validação, a partir da base vetorial.
- **Decisão:** construí RAG manual (classificador gpt-5-nano + busca vetorial) e troquei pelo file_search nativo, porque o classificador barrava buscas legítimas.

`TypeScript · Expo · Hono · Workers · Supabase · OpenAI Responses API`

Dental Smart — SaaS para clínicas odontológicas 2025 – atual

- **Multi-tenant:** SaaS em Next.js e Supabase, com isolamento por RLS no Postgres (um tenant por clínica). ~20 clínicas ativas, 0 churn.
- **Nota clínica com IA, em produção desde 02/2026:** o dentista grava a consulta, o Whisper transcreve e o Llama 3.3 70B escreve a nota em 4 blocos direto no prontuário, para o dentista revisar.
- **Integrações:** fila de mensagens de WhatsApp com variações geradas por LLM, NFS-e via Focus NFe, conciliação bancária por regras e assinatura de contrato por WhatsApp. CI no GitHub Actions e backup do banco no R2.

`Next.js · React · Supabase · Postgres RLS · Edge Functions · Groq`

Davions — SaaS de galerias para fotógrafos 2026 – atual

- **Re-hospedagem:** refatorei o app, nascido no Lovable, em 10 Cloudflare Workers com Supabase e RLS. Entregue em 10/2026.
- **Pagamentos:** arquitetei o escrow com o Asaas, com livro-razão em SQL e saque por PIX.
- **IA:** levei as 10 funções de IA do app para os Workers, via Cloudflare AI Gateway.

`TypeScript · React · Cloudflare Workers · R2 · Supabase RLS · Asaas · Stripe Connect`

HABILIDADES

IA:	LLMs (OpenAI, Anthropic/Claude, Groq, Workers AI), agentes e tool calling, RAG (file_search, vector store), structured output, guardrails, LLM-juiz, evals, speech-to-text, reconhecimento facial (AuraFace, AWS Rekognition)
Linguagens:	TypeScript, Python, SQL
Cloudflare:	Workers, Durable Objects, Queues, D1, R2, Vectorize, AI Gateway, Workers AI
AWS (projetos anteriores):	EC2, ELB, Lightsail, Lambda, SQS, S3, Aurora, Rekognition
Backend e dados:	Hono, FastAPI, Node.js, Postgres, Supabase (RLS, Edge Functions), Docker, CI (GitHub Actions)
Front e mobile:	React, Next.js, React Native / Expo
Pagamentos:	PIX, Asaas, Stripe Connect, ledger de partida dobrada

FORMAÇÃO

Sistemas de Informação (incompleto) · FAPAM · 11/2018 – 12/2020

IDIOMAS

Português (nativo) · Inglês (confortável em entrevistas técnicas)